Po czym rozpoznać gatunek irysa?

Analiza pomiarów 150 kwiatów trzech gatunków

Jerzy Śliwa

Wstęp

Irysy z tego zbioru należą do trzech gatunków: *setosa*, *versicolor* i *virginica*. Na pierwszy rzut oka kwiaty są do siebie podobne, ale różnią się wymiarami kielicha i płatka.

W tej analizie chciałem odpowiedzieć na pytanie: **które pomiary najlepiej odróżniają gatunki i czy jeden lub dwa wymiary wystarczą, żeby rozpoznać gatunek?**

Najważniejsze wyniki w skrócie

- **Wymiary płatka najlepiej odróżniają gatunki.** Kielich robi to dużo słabiej.
- ***Setosa* jest całkowicie oddzielona** od pozostałych gatunków: ma najmniejsze płatki, ale najszerszy kielich.
- ***Versicolor* i *virginica* są do siebie podobne** i różnią się głównie wielkością.
- **Pole płatka** (długość × szerokość) prawie samo rozdziela gatunki: w zakresie wspólnym *versicolor* i *virginica* jest tylko **10 na 100** kwiatów.
- **Korelacja na całym zbiorze może wprowadzać w błąd:** dla kielicha wychodzi **-0,11**, a w każdym gatunku osobno jest dodatnia.

Dane i ich jakość

Zbiór zawiera **150** kwiatów, po **50** z każdego z **3** gatunków. Dla każdego kwiatu zmierzono cztery wymiary w centymetrach, z dokładnością do 0,1 cm: długość i szerokość kielicha oraz długość i szerokość płatka. Dodałem też jedną własną kolumnę: przybliżone pole płatka (długość × szerokość).

Przed analizą sprawdziłem jakość danych:

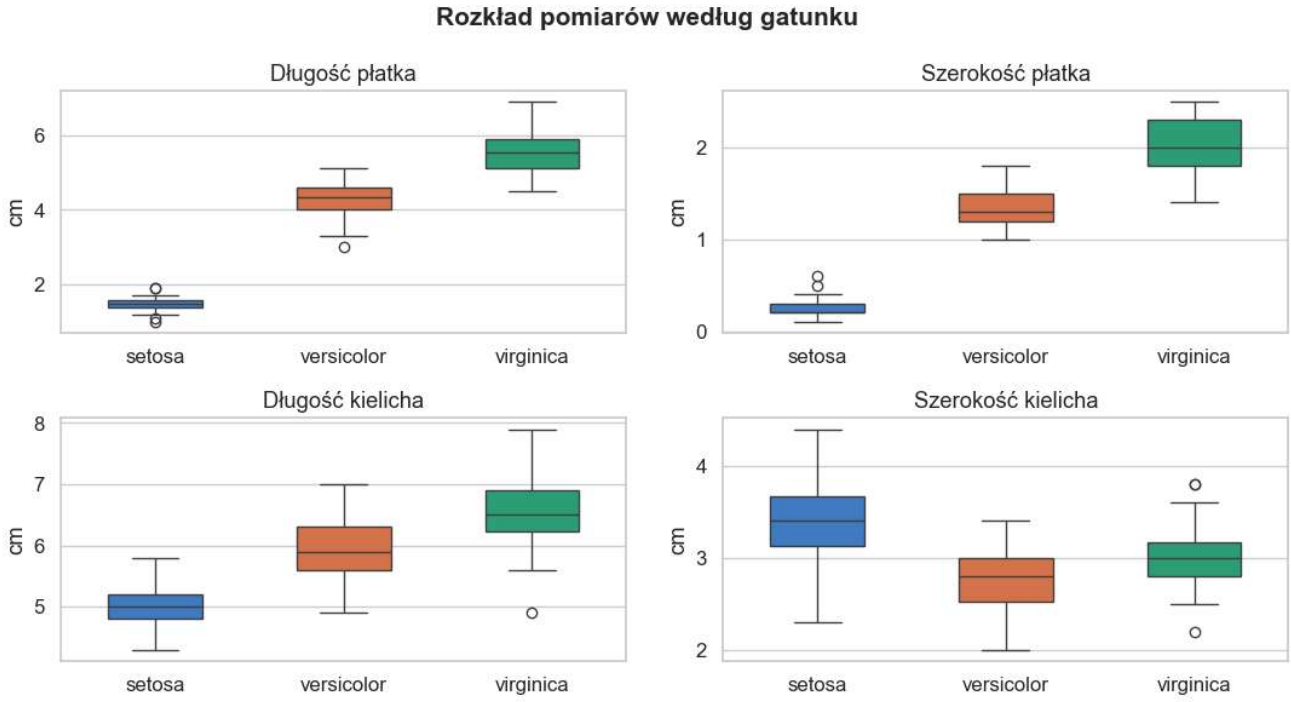
- **Brakujące wartości:** 0. Nie trzeba było niczego uzupełniać.
- **Zduplikowane wiersze:** 3. Zostawiłem je. Przy dokładności pomiaru 0,1 cm dwa różne kwiaty mogą mieć identyczne wymiary, a usunięcie duplikatów zmienia średnie najwyżej o 0,016 cm, a zaburzyłoby równy podział gatunków.
- **Wartości odstające:** 4 kwiaty, wszystkie w szerokości kielicha (trzy *setosa* z bardzo szerokim kielichem i jedna *versicolor* z bardzo wąskim). To naturalne różnice między kwiatami, a nie błędy pomiaru, więc ich nie usuwałem.

Dane nie wymagały naprawy.

Wyniki

1. Płatek rozdziela gatunki, kielich dużo słabiej

Porównałem rozkład każdego z czterech pomiarów w trzech gatunkach.



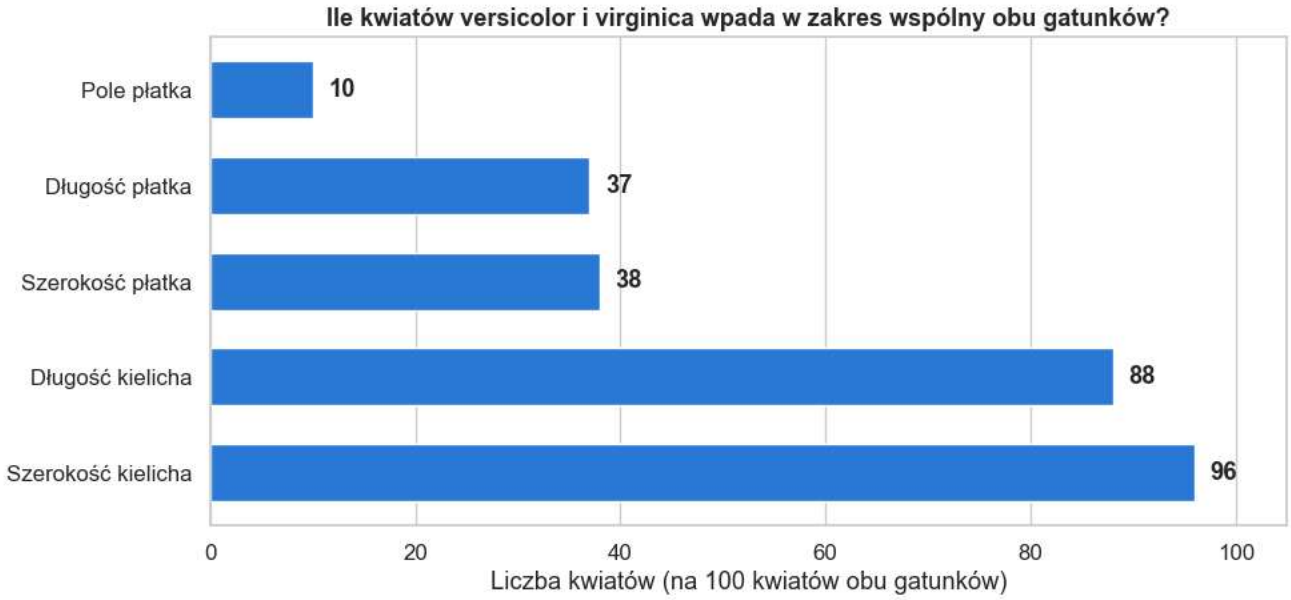
Rys. 1. Wykresy pudełkowe czterech pomiarów według gatunku.

Przy **długości i szerokości płatka** pudełka trzech gatunków w ogóle na siebie nie nachodzą. *Setosa* ma płatki krótsze niż 2 cm i węższe niż 0,7 cm, więc nie miesza się z pozostałymi gatunkami. *Virginica* ma największe płatki, *versicolor* jest pośrodku.

Przy **długości kielicha** pudełka są przesunięte, ale zakresy mocno się pokrywają. **Szerokość kielicha** zachowuje się inaczej niż reszta: to *setosa* ma najszerszy kielich, mimo że pod każdym innym względem jest najmniejsza.

2. Ile kwiatów trudno przypisać do gatunku?

Setosa łatwo odróżnić. Trudniejsza jest para *versicolor* i *virginica*, dlatego dla każdego pomiaru policzyłem, ile z tych 100 kwiatów ma wartość w zakresie wspólnym obu gatunków (czyli w przedziale, w którym występuje i jeden, i drugi gatunek).

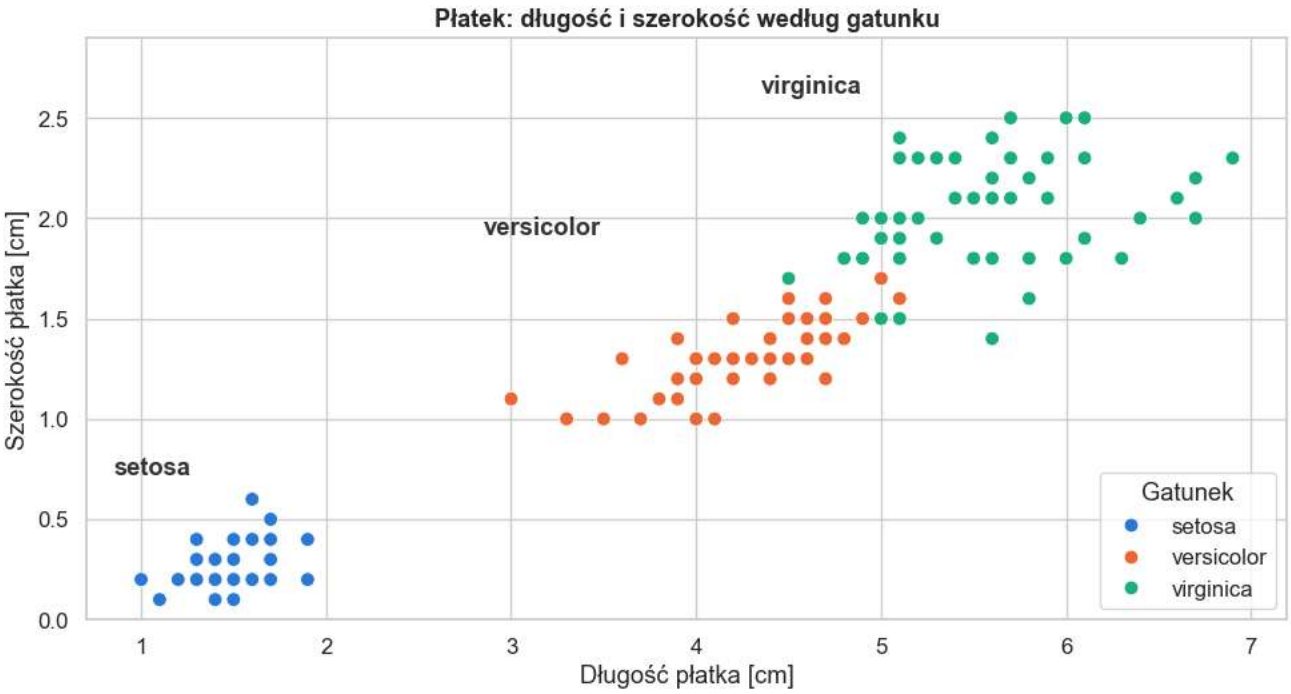


Rys. 2. Liczba kwiatów versicolor i virginica w zakresie wspólnym obu gatunków, dla każdego pomiaru.

Różnice są duże. Przy **szerokości kielicha** w zakresie wspólnym jest aż **96** kwiatów, a przy **długości kielicha 88**, więc na tej podstawie praktycznie nie da się rozróżnić tych gatunków. Przy wymiarach płatka jest to **37** (długość) i **38** (szerokość), a **pole płatka** tylko **10**.

3. Płatek: trzy wyraźne grupy

Na wykresie długości i szerokości płatka widać, jak gatunki układają się względem siebie.

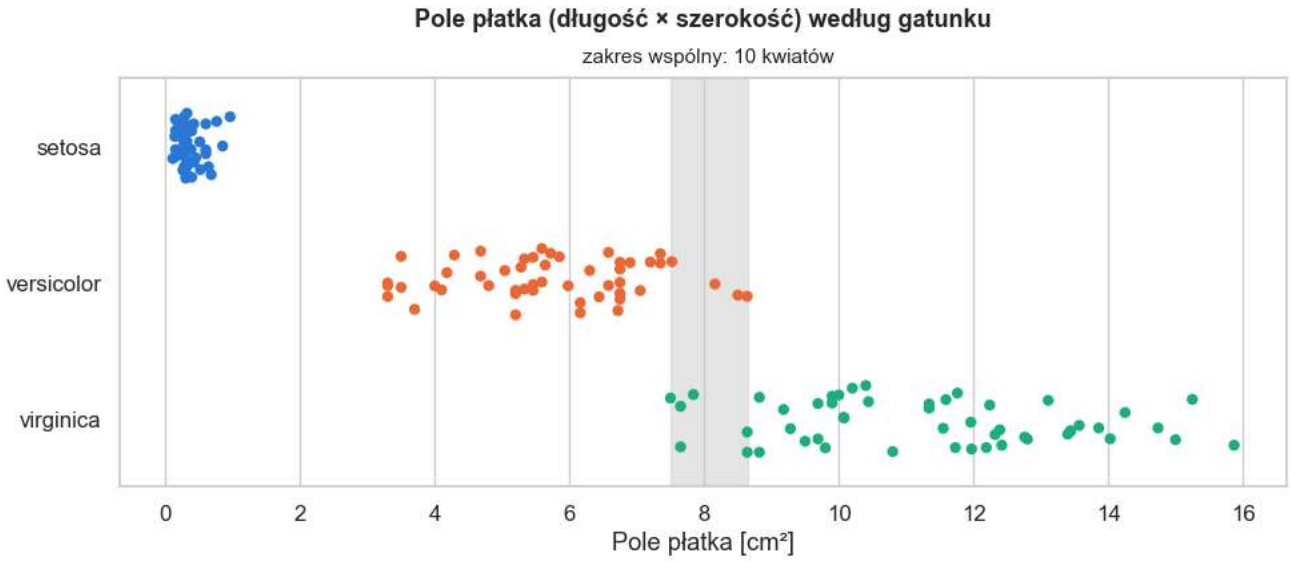


Rys. 3. Długość i szerokość płatka każdego kwiatu.

Setosa tworzy zwartą, całkowicie oddzieloną grupę w lewym dolnym rogu. *Versicolor* i *virginica* stykają się tylko w niewielkim obszarze. Długość i szerokość płatka są też bardzo silnie powiązane (korelacja 0,96): dłuższy płatek prawie zawsze jest też szerszy.

4. Pole płatka: jedna liczba prawie wystarcza

Skoro długość i szerokość płatka rosną razem, połączyłem je w jedną liczbę: pole płatka.

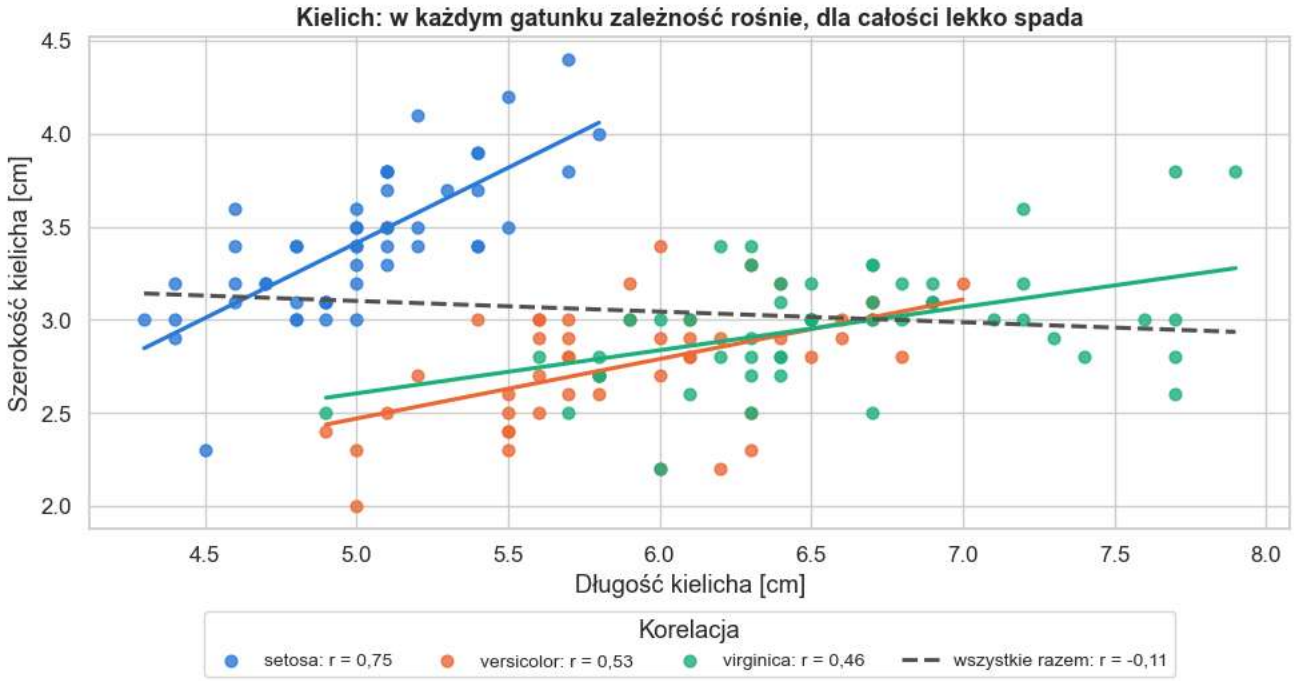


Rys. 4. Pole płatka każdego kwiatu. Szare pole to zakres, w którym występują i versicolor, i virginica.

Pole płatka *setosa* nie przekracza 1 cm². *Versicolor* i *virginica* nakładają się tylko w przedziale od 7,50 do 8,64 cm², w którym jest **10** kwiatów. Pozostałe kwiaty można przypisać do gatunku na podstawie tej jednej liczby.

5. Pułapka: korelacja dla całego zbioru

W tabeli korelacji dla wszystkich kwiatów długość i szerokość kielicha wyszły lekko ujemnie powiązane. Wynikałoby z tego, że dłuższy kielich jest węższy, co nie pasowało mi do wykresów. Sprawdziłem więc korelację w każdym gatunku osobno.



Rys. 5. Długość i szerokość kielicha z liniami trendu dla każdego gatunku (linie ciągłe) i dla wszystkich kwiatów razem (linia przerywana).

W każdym gatunku osobno korelacja jest **dodatnia** (*setosa* 0,75, *versicolor* 0,53, *virginica* 0,46), a dla wszystkich kwiatów razem lekko **ujemna** (-0,11).

Dzieje się tak, bo *setosa* ma krótkie, ale szerokie kielichy, a pozostałe gatunki długie i węższe. Po połączeniu grup zależność się odwraca. Wniosek ogólny: korelacji policzonej na całym zbiorze nie można interpretować bez sprawdzenia, czy w danych nie ma różnych grup.

Wnioski

1. **Wymiary płatka najlepiej odróżniają gatunki.** Pudełka trzech gatunków nie nachodzą na siebie, a na wykresie punktowym tworzą trzy wyraźne grupy.
2. ***Setosa* wyraźnie różni się od pozostałych gatunków:** ma płatki krótsze niż 2 cm i węższe niż 0,7 cm, a jednocześnie najszerszy kielich.
3. ***Versicolor* i *virginica* są do siebie podobne**, różnią się głównie wielkością (*virginica* jest większa), a ich zakresy częściowo się nakładają.
4. **Pole płatka** prawie samo rozdziela gatunki.
5. **Szerokość kielicha** najsłabiej odróżnia gatunki.
6. **Korelacja na całym zbiorze może wprowadzać w błąd.** Wyniki dla całości warto zawsze porównać z wynikami w grupach.

Ograniczenia

- Zbiór jest mały: 50 kwiatów na gatunek. Zakresy wartości (minimum i maksimum) na większej próbie mogą być szersze, więc zakres wspólny *versicolor* i *virginica* może się powiększyć.
- Z danych nie da się sprawdzić, czy zduplikowane wiersze to różne kwiaty, czy błąd zapisu, bo nie ma numeru próbki ani daty pomiaru.

Co dalej

Na podstawie wymiarów płatka można spróbować zbudować prostą regułę lub model, który automatycznie rozpozna gatunek, i sprawdzić, jak często się myli przy *versicolor* i *virginica*.