Po czym rozpoznać gatunek irysa?

Analiza pomiarów 150 kwiatów trzech gatunków

Jerzy Śliwa

Cel analizy

Chciałem sprawdzić, które pomiary kwiatu najlepiej odróżniają trzy gatunki irysów: *setosa*, *versicolor* i *virginica*.

Dane

Zbiór zawiera **150** kwiatów, po **50** z każdego z **3** gatunków.

Dla każdego kwiatu zmierzono **4 wymiary** w centymetrach: długość i szerokość kielicha oraz płatka.

Dane

Zbiór zawiera **150** kwiatów, po **50** z każdego z **3** gatunków.

Dla każdego kwiatu zmierzono **4 wymiary** w centymetrach: długość i szerokość kielicha oraz płatka.

Długość kielicha	Szerokość kielicha	Długość płatka	Szerokość płatka	Gatunek
6.1	2.8	4.7	1.2	versicolor
5.7	3.8	1.7	0.3	setosa
7.7	2.6	6.9	2.3	virginica
6.0	2.9	4.5	1.5	versicolor
6.8	2.8	4.8	1.4	versicolor

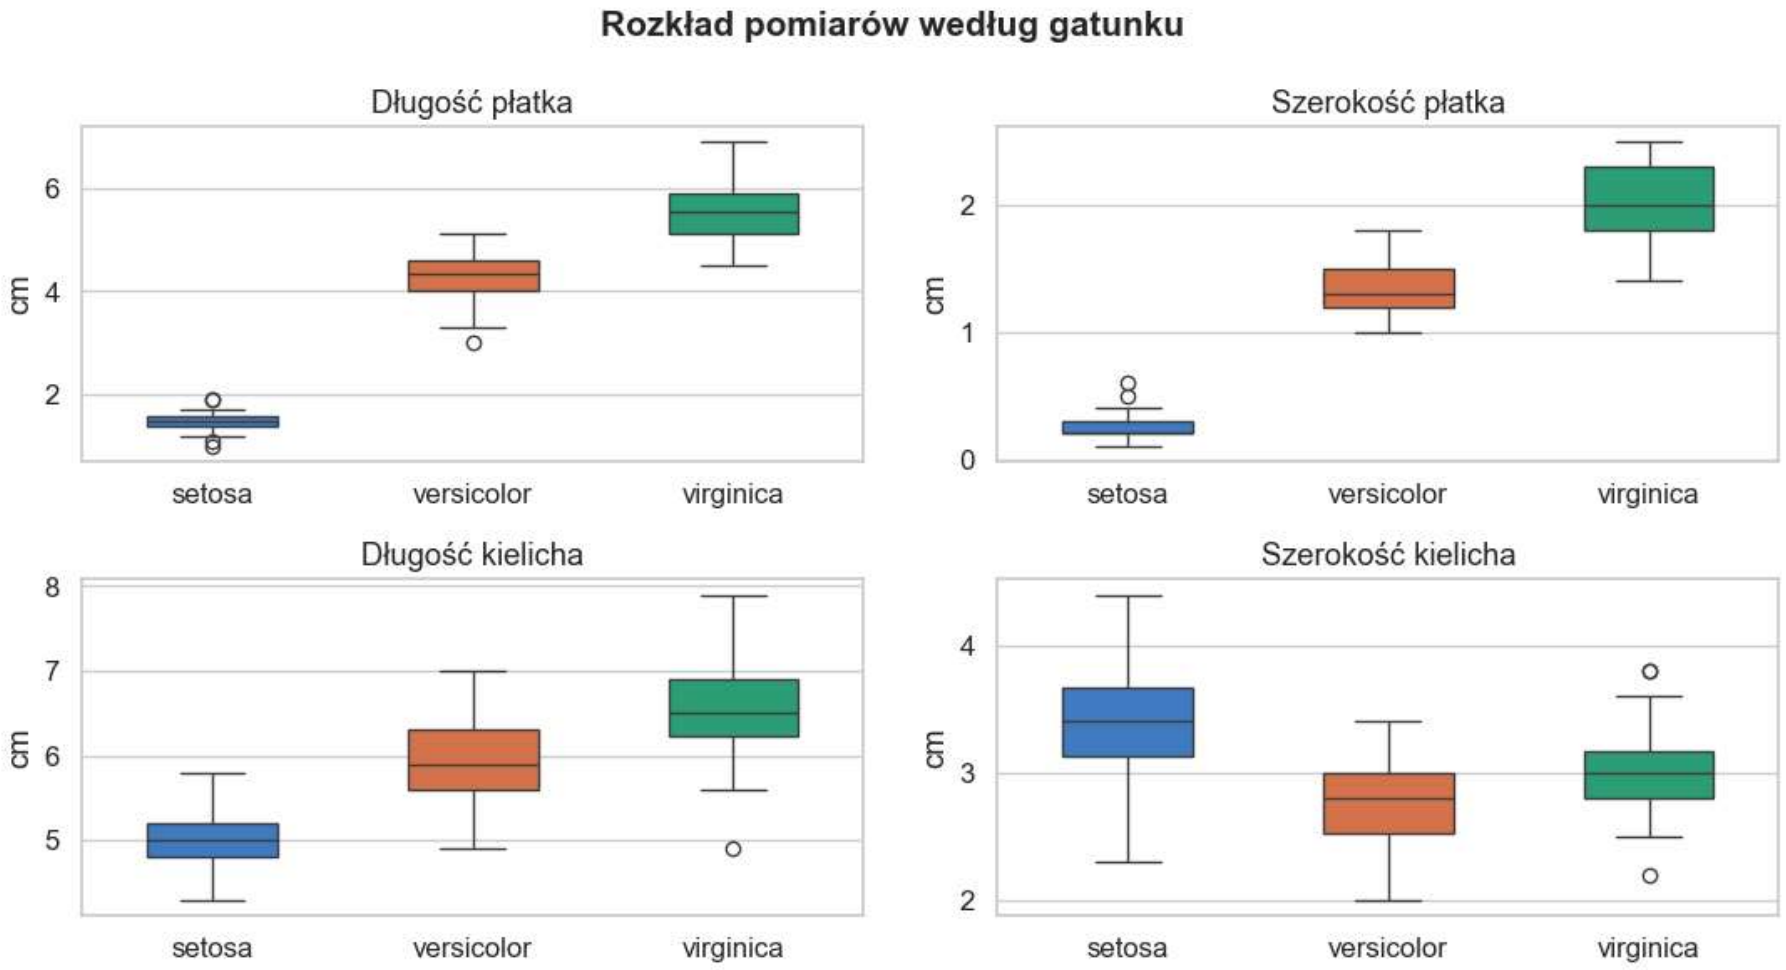
Jakość danych jest dobra

- Brakujące wartości: **0**
- Zduplikowane wiersze: **3**. Zostawiłem je, bo po ich usunięciu średnie zmieniają się najwyżej o **0,016 cm**, a przy dokładności pomiaru 0,1 cm dwa różne kwiaty mogą mieć takie same wymiary.
- Wartości odstające: **4** kwiaty (szerokość kielicha). To naturalne różnice między kwiatami, a nie błędy, więc też je zostawiłem.

Który pomiar najlepiej odróżnia gatunki?

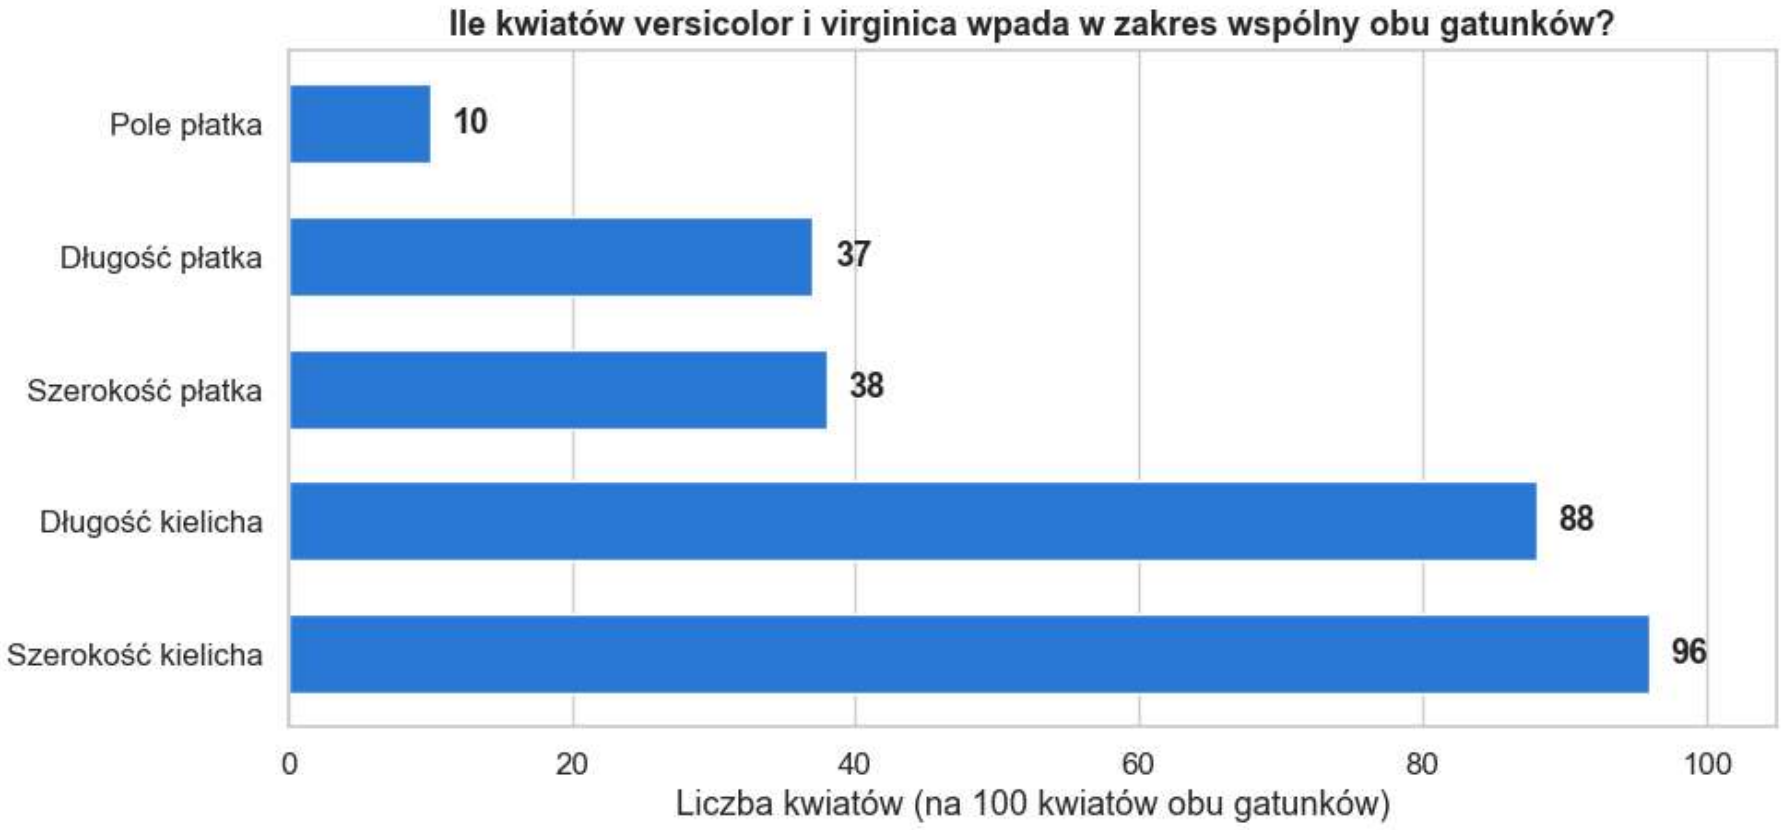
Płatek wyraźnie rozdziela gatunki, kielich dużo słabiej

Płatek wyraźnie rozdziela gatunki, kielich dużo słabiej



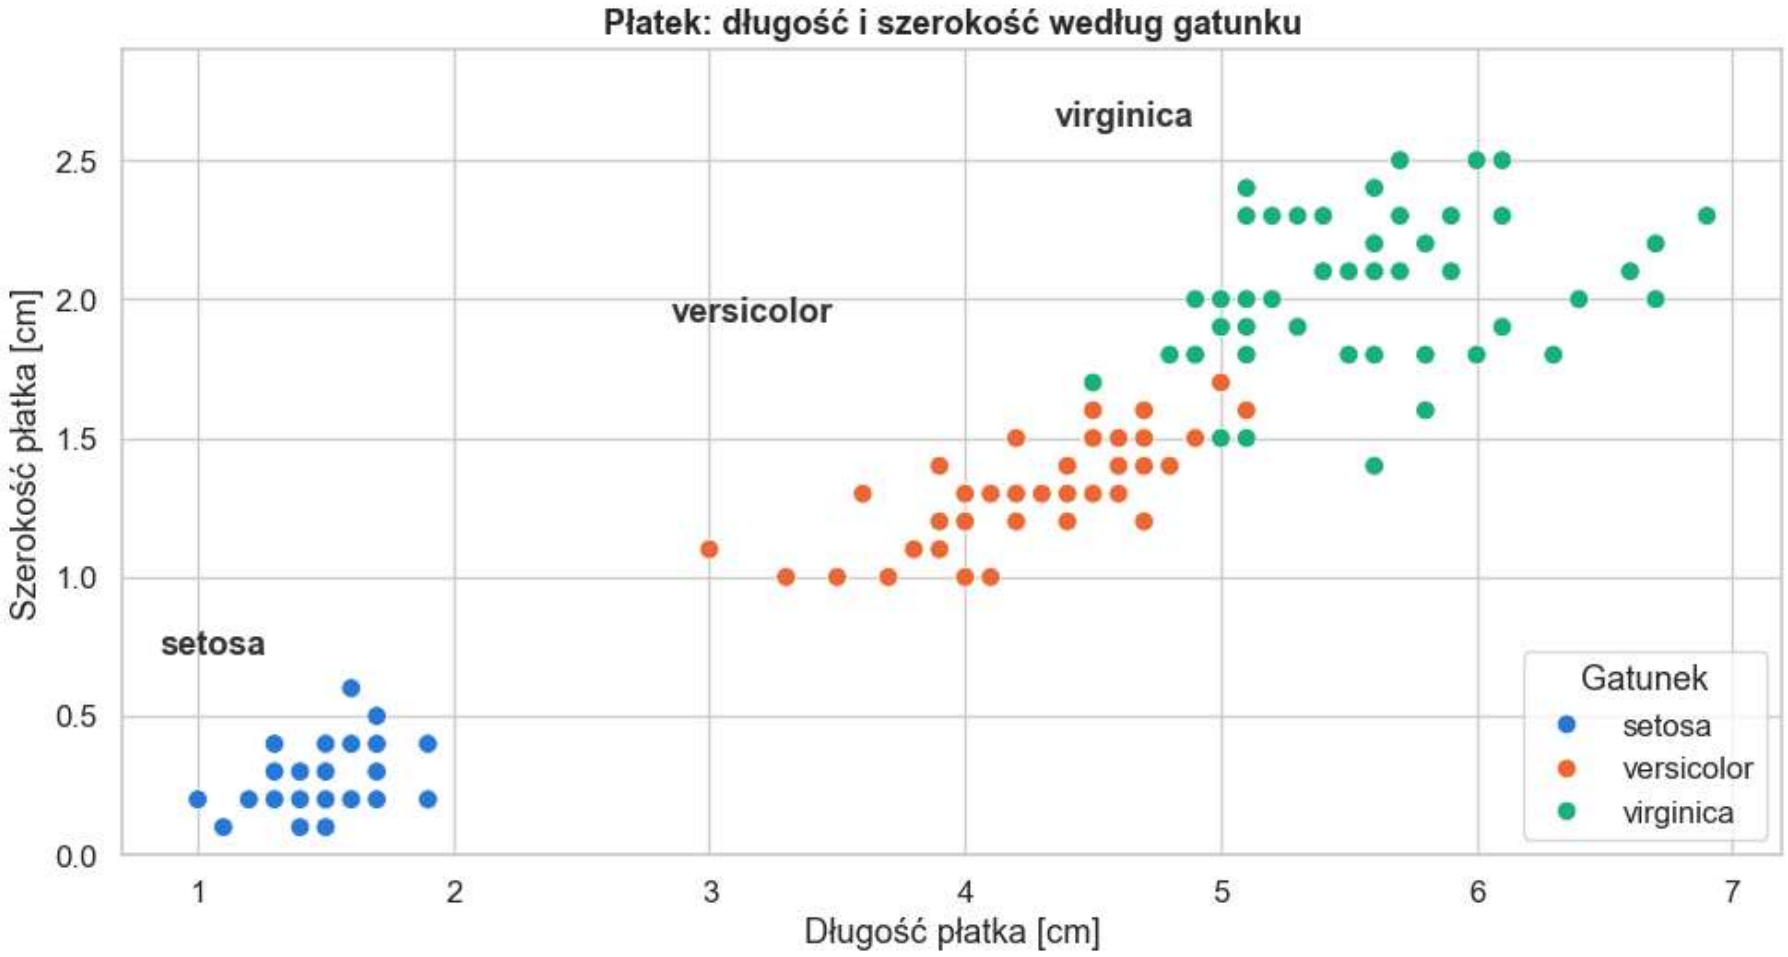
Versicolor i virginica są do siebie podobne. Przy szerokości kielicha aż **96 na 100** kwiatów wpada w zakres wspólny obu gatunków, przy polu płatka tylko **10**

Versicolor i virginica są do siebie podobne. Przy szerokości kielicha aż **96 na 100** kwiatów wpada w zakres wspólny obu gatunków, przy polu płatka tylko **10**



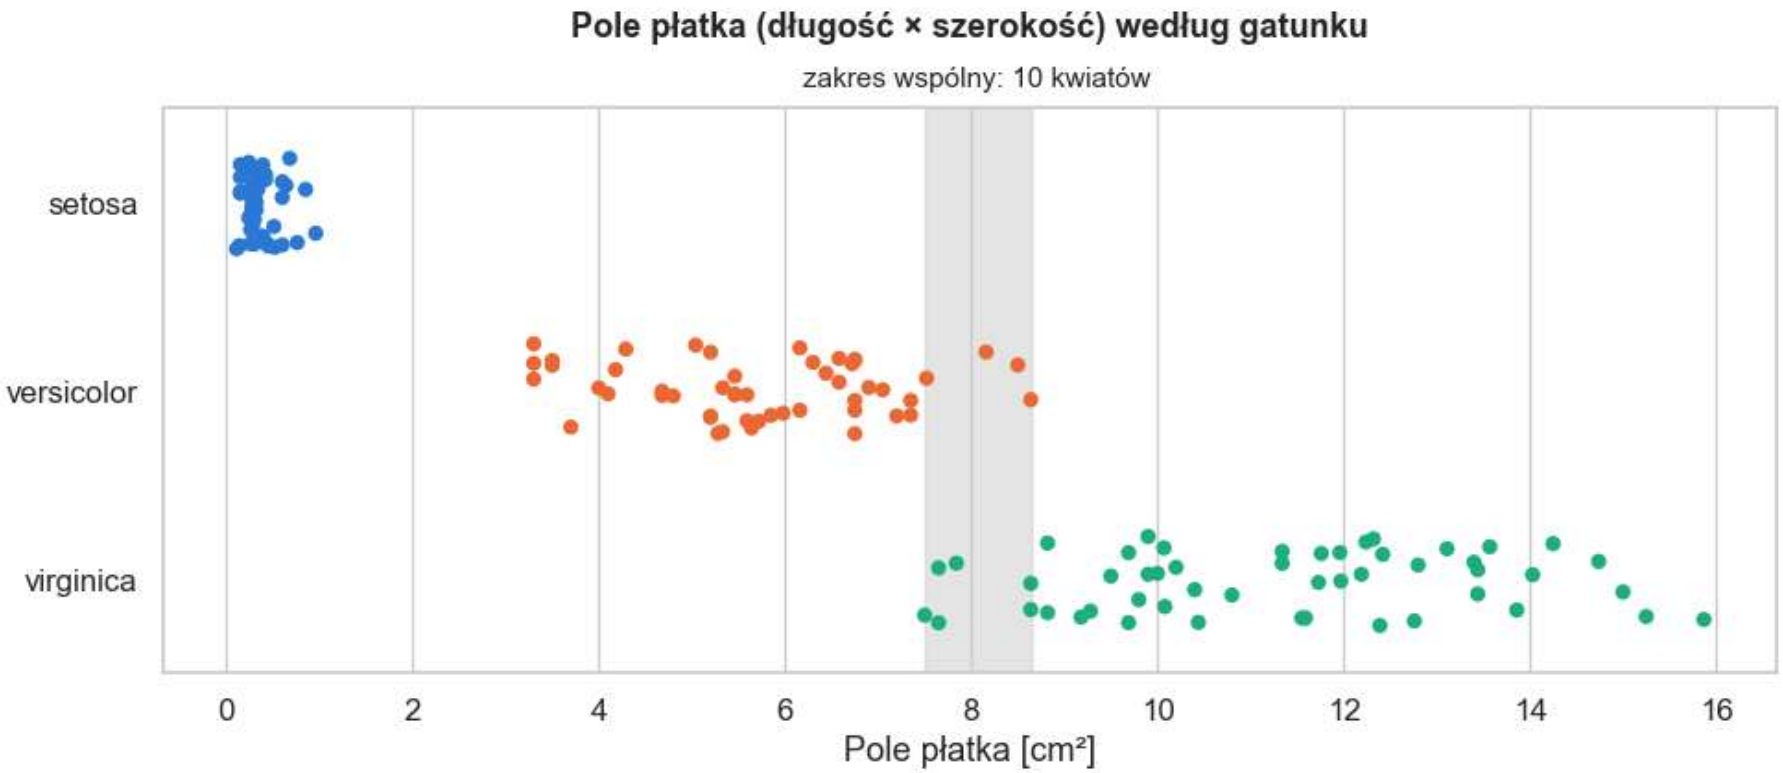
Setosa jest całkowicie oddzielona, a *versicolor* i *virginica* stykają się tylko w niewielkim obszarze

Setosa jest całkowicie oddzielona, a *versicolor* i *virginica* stykają się tylko w niewielkim obszarze



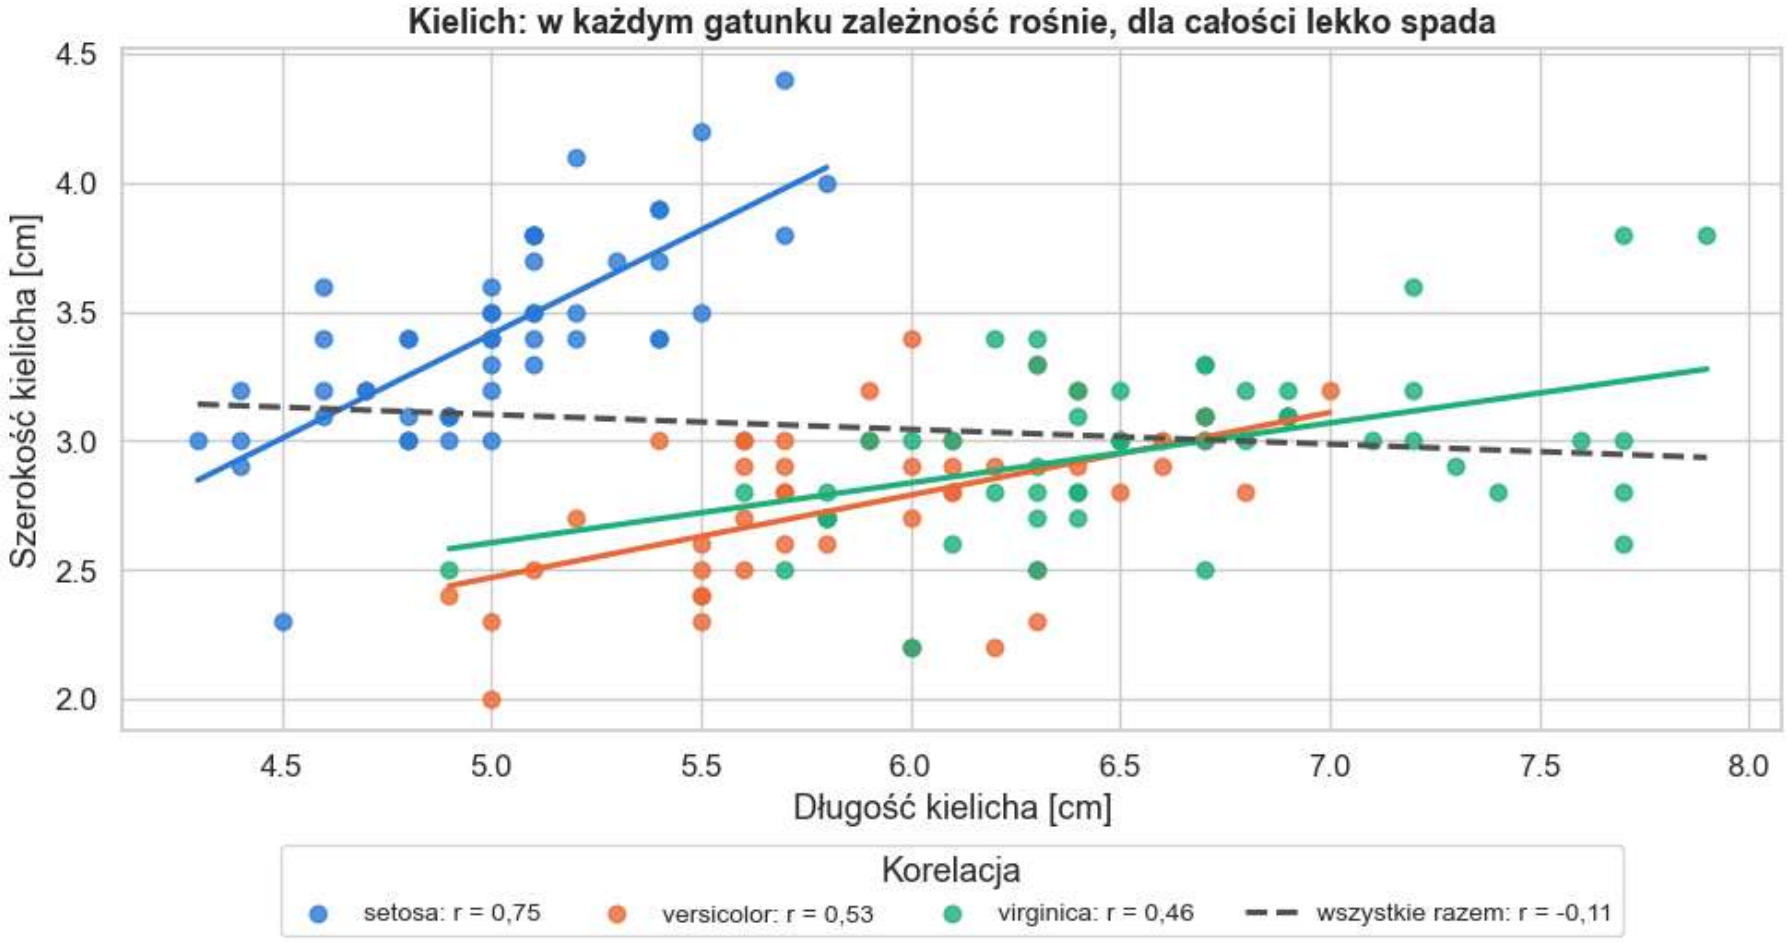
Jedna dodatkowa kolumna, pole płatka, prawie sama rozdziela gatunki: *setosa* poniżej 1 cm^2, a w zakresie wspólnym *versicolor* i *virginica* jest tylko **10** kwiatów

Jedna dodatkowa kolumna, pole płatka, prawie sama rozdziela gatunki: *setosa* poniżej 1 cm^2, a w zakresie wspólnym *versicolor* i *virginica* jest tylko **10** kwiatów



Uwaga na korelację liczoną na całym zbiorze: dla kielicha wychodzi **-0,11**, a w każdym gatunku osobno jest dodatnia (od **0,46** do **0,75**)

Uwaga na korelację liczoną na całym zbiorze: dla kielicha wychodzi **-0,11**, a w każdym gatunku osobno jest dodatnia (od **0,46** do **0,75**)



Dlaczego tak wychodzi?

Setosa ma krótkie, ale szerokie kielichy, a pozostałe gatunki długie i węższe.
Po połączeniu grup zależność się odwraca.

Wniosek: korelację liczoną na całym zbiorze trzeba sprawdzić w grupach.

Wnioski

1. **Wymiary płatka najlepiej odróżniają gatunki.**
2. ***Setosa* różni się od pozostałych najbardziej**: ma najmniejsze płatki, ale najszerszy kielich.
3. ***Versicolor* i *virginica* są podobne**, różnią się głównie wielkością.
4. **Pole płatka** prawie samo rozdziela gatunki.
5. **Szerokość kielicha** najsłabiej odróżnia gatunki.
6. **Korelację na całym zbiorze trzeba sprawdzać w grupach**, bo może dać odwrotny obraz.

Co dalej?

Na podstawie wymiarów płatka można spróbować zbudować prostą regułę lub model, który automatycznie rozpozna gatunek, i sprawdzić, jak często się myli przy *versicolor* i *virginica*.

Dziękuję